

基于支持向量机的船舶柴油机故障诊断

朱志宇, 刘维亭

(江苏科技大学 电子信息学院, 镇江 212003)

摘要: 介绍了支持向量机(SVM)的机理, 应用 SVM 对船舶电站主柴油机进行故障诊断, 研究了 SVM 参数的选择方法, 仿真结果表明, SVM 具有较好的诊断效果和较强的抗噪声能力; 对复合故障样本诊断准确度较 RBF 神经网络高。

关键词: 柴油机; 故障诊断; 支持向量机

中图分类号: U664.121; TP206.3 **文献标识码:** A **文章编号:** 1000-6982(2006)05-0031-03

Fault diagnosis of marine diesel engine based on support vector machine

ZHU Zhi-yu, LIU Wei-ting

(Dept. of Electronics and Information, Jiangsu University of Science and Technology, Zhenjiang 212003, China)

Abstract: The mechanism of support vector machine (SVM) is first introduced in this paper. Then SVM is applied to diagnose faults of marine diesel engine. The method to choose parameters of SVM is studied. The simulation result shows that SVM has good diagnosis effect and strong ability to resist noise. Compared with RBF neural network, SVM has higher diagnosis accuracy on compound fault samples.

Key words: diesel engine; fault diagnosis; support vector machine (SVM)

0 引言

船舶主柴油机是一个复杂的机电系统, 其故障规律很难用简单的数学模型描述。尽管神经网络在智能故障诊断系统中获得了广泛的应用, 但神经网络普遍存在着在线学习速度慢、网络结构难以确定、局部最优、泛化能力差等缺点。最近几年发展起来的支持向量机(support vector machine, SVM)建立在统计学习理论的 VC 维理论和结构风险最小原理上, 其核心思想是使样本之间的分类间隔最大化。它能较好地解决小样本、非线性、高维数和局部极小点等实际问题, 比传统神经网络具有更强的分类能力和泛化能力, 学习算法效率较高, 并且巧妙地解决了维数灾难问题^[1]。因此 SVM 目前已成为机器学习界研究的热点, 并成功地应用于分类、函数逼近和故障诊断等方面^[2-5]。

故障诊断的瓶颈之一是故障样本的缺乏, 鉴于 SVM 在训练样本很少的情况下能很好地达到分类推广的目的, 本研究尝试采用 SVM 对船舶主柴油机进行故障诊断。

1 基于支持向量机的故障诊断机理

设有 n 个训练样本, 将支持向量机用于故障诊断, 就是在样本特征空间内寻找中心为 $a \in R^1$, 半径为 $R \in R^d$ 的超球, 使正常样本点位于超球内, 异常点位于超球之外, 从而实现分类目的。超球体积要尽量小, 以尽量减少接受异常样本点的机会。因此, 故障诊断问题可用下述优化问题来描述, 并求解最小的超球半径 R :

$$\begin{aligned} \min(R^2 + C \sum_i \xi_i) \\ \text{s.t. } \|x_i - a\|^2 \leq R^2 + \xi_i \\ \xi_i \geq 0, i = 1, 2, \dots, n \end{aligned} \quad (1)$$

式中, x_i 为第 i 个样本点; ξ_i 为松弛变量, 是考虑到有一些样本不能被超平面正确分类专门设置的; C 为权值系数, 它的作用是控制对错分样本(个别样本点出现在超球以外)惩罚的程度。 C 越大, 表示要求实现较小的分类间隔, $C = \infty$ 时, 表示要求无错分样本。

可将上述优化问题转化为一个二次规划问题, 它有唯一的极小点, 可用 Lagrange 乘子法解决。定义 Lagrange 函数 $L(R, a, \xi, \alpha, \gamma)$ 为:

收稿日期: 2005-08-31; 修回日期: 2005-11-28

作者简介: 朱志宇(1971-), 男, 博士, 副教授, 主要研究方向: 船舶运动控制、船舶自动化。

$$L(R, a, \xi, \alpha, \gamma) = R^2 + C \sum_i \xi_i - \sum_i \alpha_i (R^2 + \xi_i - \|x_i - a\|^2) - \sum_i \gamma_i \xi_i \quad (2)$$

式中, $\alpha_i \geq 0$ 、 $\gamma_i \geq 0$ 为 Lagrange 乘子. Lagrange 函数对 R 、 a 、 ξ_i 分别求偏导并令求导结果等于 0, 得到:

$$\sum_i \alpha_i = 1 \quad (3)$$

$$a = \sum_i \alpha_i x_i \quad (4)$$

$$\gamma_i = C - \alpha_i \quad (5)$$

将以上三个公式代入 Lagrange 函数 (2), 得到对偶优化问题的目标函数为:

$$W(\alpha) = \sum_i \alpha_i K(x_i, x_i) - \sum_{i,j} \alpha_i \alpha_j (x_i, x_j) \quad (6)$$

式中, (x_i, x_j) 表示欧式空间中的内积; (x_i, x_j) 为核函数. 这样, 原问题的对偶问题转化为:

$$\begin{aligned} \max W(\alpha) \\ \text{s.t. } \sum_i \alpha_i = 1, 0 \leq \alpha_i \leq C \end{aligned} \quad (7)$$

其 KKT 条件为:

$$\begin{aligned} \alpha_i (R^2 + \xi_i - \|x_i - a\|^2) &= 0 \\ \gamma_i \xi_i &= 0 \end{aligned} \quad (8)$$

采用顺序最小优化方法对上式求解, 可得到 α_i , 由式 (4) 知, 球心 a 为所有样本点 x_i 的加权平均, 加权系数就是 α_i , 注意到只有少部分 α_i 的数值大于零, 其他均为零, 称对应 $\alpha_i > 0$ 的样本点为支持向量.

支持向量可分为两类^[3], 若 $C = \alpha_i$, 可得: $\xi_i > 0$, $R^2 + \xi_i = \|x_i - a\|^2$, 从而 $\|x_i - a\|^2 \geq R^2$, 此时对应的样本数据位于超球面上或超球外部; 若 $C > \alpha_i$, 则 $\|x_i - a\|^2 = R^2$, 说明对应的样本数据位于超球面上. 通过调节 C 的大小可调整位于超球面外部的样本点数, C 越大, 位于超球面外部的样本数据就越少.

在通过优化计算得到超球半径 R 后, 计算样本数据到球心的距离 $\|x_i - a\|$, 若该距离不超过 R , 即样本位于超球内, 则说明该样本为正常值, 否则为故障点.

2 船舶主柴油机故障诊断

船舶柴油机是一个复杂机电系统, 采用整机诊断模型非常复杂, 如果仅采用一个支持向量机会使网络规模庞大, 学习训练困难. 考虑到系统故障具有层次性的特点, 因此本文采用层次诊断模型方法. 将整机分成增压系统、燃烧系统、润滑系统、燃油系统、冷却系统和传动系统等子系统, 如图 1 所示. 首先由整机性能参数的恶化状态判断故障可能发生在哪个子系统, 称为第一层次诊断, 然后对该子系统进一步诊断出故障的原因、位置和程度, 称为第二层次诊断. 限于篇幅, 本文仅介绍对燃油系统进行故障诊断的结果.

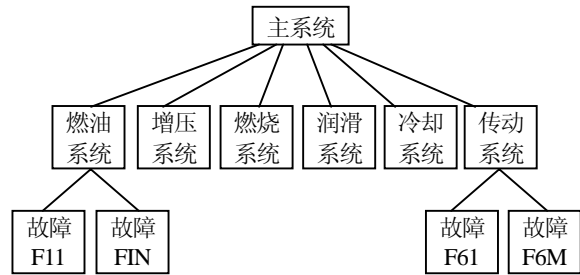


图 1 主柴油机故障诊断系统的层次分类模型

2.1 船舶主柴油机燃油系统故障机理

本文考虑来自传感器的样本信号分别为燃油流量 Q 、燃油压力 P 和燃油粘度 μ , 即 $X = \{Q, P, \mu\}$, 每个输入数据用 3 种状态来表示, 即 Normal, High, Low, 分别记为 N, H, L . 考虑该子系统有九种基本故障现象, 记为 $F = \{F_0, F_1, \dots, F_9\}$, 其中 F_0 : 无故障; F_1 : 喷油器喷孔变大; F_2 : 喷油器喷孔堵塞; F_3 : 燃油泵堵塞; F_4 : 燃油系统泄露; F_5 : 燃油混有杂质; F_6 : 燃油粘度偏低; F_7 : 供油角延后; F_8 : 供油角提前; F_9 : 后燃.

故障样本集的确定是 SVM 进行准确诊断的关键. 根据船舶航行过程中的实际状况, 在不同的环境温度及不同的柴油机负荷条件下, 采集给定故障状态下的柴油机运行工况参数, 在获得给定工况和设置故障下的过程参数的测量值后, 以该工况无故障条件下各处的参数值作为基准值. 实测值与基准值的偏差经过处理获得诊断用的征兆集, 从而建立起船舶柴油机的故障样本集.

参照文献[6], 对每种故障采样 4 个样本数据, 同时为了反映机组运行负荷与故障之间的对应关系, 考虑额定负荷 (100% MCR)、部分负荷 (90% MCR、75% MCR) 和半负荷 (50% MCR) 四种工况; 再考虑到船舶航行环境的大气温度变化, 选取有代表性的大气温度为 288K、300K、312K, 最后共得到 432 个样本, 将前 216 个数据样本用于训练, 后 216 个数据样本作为检验样本.

2.2 基于支持向量机的故障诊断方法

关于如何设置 SVM 的各个参数, 理论上还没有统一的论述, 往往要针对待解决的实际问题具体选择. 在本文的故障诊断中, 采用 RBF 核函数, 也称为高斯函数:

$$k(x_i, x_j) = \exp \left\{ -\frac{\|x_i - x_j\|^2}{\sigma^2} \right\}, \quad i = 1, 2, \dots, n \quad (9)$$

式中, σ 是感知变量, 它决定了高斯函数的宽度. σ 的数值可以控制支持向量机的个数, 当支持向量机个数太多时, 可以适当减小 σ 的数值, 反之亦然. 目前还没有统一的方法来确定 σ 的数值, 一般根据特征数据分析的结果取经验值. 为简单起见, 本文采用以下经验公式确定 σ 的数值: $\sigma^2 = E(\|x_i - x_j\|^2)$, 其中 E 表示数学期望.

参数 C 的选择： C 为惩罚参数，一般也是通过试验来找到对特定训练集最好的 C 的数值，本文取 $C=100$ 。

应用SVM进行故障诊断的步骤如下：（1）在获得了样本数据后，首先对数据进行归一化处理，以消除量纲的影响；（2）选择非线性映射函数 ϕ ，满足 $K(x_i, x_j)=\phi(x_i) \cdot \phi(x_j)$ ，将训练数据通过 ϕ 映射到高维特征空间；（3）选择上述的核函数 $K(x_i, x_j)$ 和惩罚参数 C ，利用训练样本以及式（8）所示的KKT条件，求解式（7）所示的二次优化问题，以获得对应的支持向量 α_i 、球心 a 以及超球半径 R ；（4）根据步骤（3）得到的参数值，计算样本数据到球心的距离，若该距离不超过 R ，即样本点位于超球内，则说明该样本数据为正常值，否则为故障点；（5）对所有的训练样本，重复步骤（2）~（4）。

2.3 仿真结果

表1 SVM故障诊断结果

序 号	模拟 故障	特征征兆			诊断 结果
		Q	P	μ	
1	F_1	H	$0.9N$	N	F_1
2	F_2	L	$0.8N$	$1.2N$	F_2
3	F_3	L	$0.9H$	$0.8N$	F_3
4	F_4	$1.2L$	L	$0.7N$	F_4
5	F_5	L	$1.3N$	$0.9H$	F_5
6	F_6	$1.1N$	$0.8N$	$0.8L$	F_6
7	$F_1 F_4$	$0.8H$	$1.2L$	$0.8N$	$F_1 F_4$
8	$F_2 F_5$	L	$0.8H$	$0.8H$	$F_2 F_5$
9	$F_2 F_6$	$1.2L$	$0.8N$	$1.1L$	$F_2 F_6$
10	$F_1 F_5$	$0.8H$	$0.9N$	$0.8H$	$F_1 F_5$

表3 误诊样本数

故障类型		F_1	F_5	F_9	$F_1 F_4$	$F_1 F_5$	$F_2 F_5$	$F_2 F_6$	$F_1 F_2 F_5$	$F_3 F_5 F_7$	$F_5 F_7 F_9$
误诊样	RBF	0	0	1	2	3	3	4	6	8	9
本数	SVM	0	0	0	0	1	1	1	2	3	3

3 结语

本文探讨了SVM的机理，应用SVM对船舶主柴油机进行故障诊断，讨论了SVM参数的选择方法。仿真结果表明，SVM具有较好的诊断效果，较强的抗噪声能力；与RBF神经网络相比，SVM对复合故障样本诊断的准确度较高。

参考文献：

- [1] Vapnik V N 著，张学工译. 统计学习理论的本质[M]. 北京：清华大学出版社，2000.
- [2] Tay Francis E H, Cao Li-juan. ϵ -descending support vector machines for financial time series forecasting [J]. Neural

Processing Letters, 2002, 15(2): 179-195.

为了防止测量值的波动对SVM学习的影响，对样本数据做归一化处理： H 对应1， N 对应0， L 对应-1. 对SVM训练和测试后，表1给出了故障诊断实例。

表1中的结果表明，SVM能够正确地分类故障样本，同时对偏离训练样本的输入数据依然具有较强的处理能力。为了进一步验证SVM抵抗噪声的能力，在测试样本中叠加噪声，重新测试其分类性能。模拟传感器有故障或数据处理有误的情况，重新测试其分类性能。例如当输入样本为 $X=\{Q, P, \mu\}=\{H, N, N\}$ 时，故障诊断结果为 F_1 ，使该样本偏离上述标准数值，重新测试，得到如表2所示的诊断结果：

表2 SVM对叠加噪声后的样本的故障诊断结果

序	特征征兆			诊断
	Q	P	μ	
1	H	N	N	F_1
2	H	$1.2N$	$1.2N$	F_1
3	H	$0.7N$	$0.6N$	F_1
4	$1.2H$	$1.3N$	$0.7N$	F_1
5	$0.8H$	$0.7N$	$1.4N$	F_1

表2的结果表明，加入噪声后，最终的故障分类结果依然是正确的，说明SVM具有较强的抗噪声能力。

分别采用SVM和RBF网络，学习同一批训练样本和测试样本（叠加噪声），表3给出了两种方法的误诊样本数，表明SVM对复合故障样本有较高的诊断准确度，而RBF神经网络对复合故障样本诊断的准确度不高，这也从另一个侧面说明SVM具有很强的分类能力。

- [3] 翟永杰，韩埃，王东风等. 基于损失函数的SVM算法及其在轻微故障诊断中的应用[J]. 中国电机工程学报，2003，23（9）：198-203.
- [4] 郝英，孙健国，白杰. 基于支持向量机及油中溶解气体分析的大型电力变压器故障诊断模型研究[J]. 中国电机工程学报，2003，23（7）：88-92.
- [5] 胡寿松，王源. 基于支持向量机的非线性系统故障诊断[J]. 控制与决策，2001，15（5）：617-620.
- [6] 黄加亮，蔡振雄. 船舶柴油机运行工况诊断仿真研究[J]. 船舶工程，2002，24（6）：31-34.